

FORWARD DEPLOYED ENGINEERING

FDE

橙皮书

从业务现场到 AI 系统交付

认识 FDE / 技术基础 / 交付实务 / 案例拆解

按章阅读 · 27 章 · 公开来源与实践练习

阅读说明

企业购买了模型服务，项目仍有很多事情要做。业务人员的任务要重新梳理，散落在系统里的资料要能被正确调用，模型给出的结果要有人验收，出错以后还得有办法继续工作。FDE 的工作就在这些具体环节里。

本书把 FDE 译为前线部署工程师，英文为 Forward Deployed Engineer。不同公司的岗位名称和职责并不完全一致。本书用它指代一种靠近客户业务、参与构建并持续对交付结果负责的工程工作方式。

这次编写重新核对了企业官方案例、工程文档、公开培训课程和 Datawhale 的实践材料。事实能够支持到哪里，案例就写到哪里。没有公开的团队人数、架构细节和经济结果，不用推测补齐。

怎样读这本书

全书分为四篇。第一篇建立岗位与业务认知，第二篇解释技术基础，第三篇沿着项目推进学习交付方法，第四篇用真实案例检查前面的方法。第一次阅读建议顺序读完前三篇，再挑选自己行业的案例。

有工程经验的读者可以重点读第 2、3、11、12、16、17 章。业务负责人可以先读第一篇，再读需求发现、范围、采用与交接。刚接触 AI 的读者应把第二篇的术语和流程图读熟，不必一次学会所有工具。

每章提出一个具体问题，解释必要概念，给出可以执行的工作方法，并留下一项练习或交付物。练习属于本书设计的教学任务，不代表任何公司的真实内部流程，也不构成医疗、金融、法律或安全合规建议。

怎样读案例

本书用 A、B、C、D 区分材料性质。A 为企业官方资料或正式文件，B 为有编辑核验的媒体报道，C 为社区或社交平台自述，D 为本书的分析与教学设计。A 表示来源直接，不表示结果经过独立审计。

案例的价值在于让读者看见工程问题怎样与业务相连。采用人数、节省时间、自动化率各有统计范围。它们不能相互替代，也不能直接换算成收益或岗位减少。特别是供应商发布的成功故事，应当连同其未披露的信息一起阅读。

关于版本与资料

新版书名统一为《FDE橙皮书》，副标题为《从业务现场到 AI 系统交付》。章节 Markdown 是内容来源，PDF 和阅读版从同一份章节生成。旧书稿和研究文件保留用于追溯，不再充当主目录。

参考范冰的公开 FDE 指南时，本书仅学习按章阅读和整本下载的组织方式，不复制其正文。国内案例保留 Datawhale 原始链接。推荐课程不构成培训机构背书，完成课程也不等同于具备生产交付能力。

目录

页码与 PDF 实际页序一致。目录及书签均可点击。

阅读说明	2
第一篇 认识 FDE	6
第 1 章 FDE 的工作与责任	7
第 2 章 用业务流程理解问题	9
第 3 章 价值指标与成本	11
第 4 章 能力地图与协作边界	13
第二篇 技术基础	15
第 5 章 大模型与上下文	16
第 6 章 数据、接口与业务对象	18
第 7 章 RAG 与企业知识	20
第 8 章 工作流、Agent 与 MCP	22
第 9 章 评测与错误分析	24
第 10 章 权限、安全与人工控制	26
第三篇 交付实务	28
第 11 章 需求发现与现场访谈	29
第 12 章 范围与验收约定	31
第 13 章 原型与受控试点	33
第 14 章 生产发布与回退	35

第 15 章 可观测性与故障处理	37
第 16 章 用户采用与运营交接	39
第 17 章 团队组织与复用	41
第 18 章 学习路线与作品集	43
 第四篇 案例拆解	 45
第 19 章 Airbus，让数据进入维修决策	46
第 20 章 Tampa General，医院运营协同	48
第 21 章 Morgan Stanley，把评测放进开发	50
第 22 章 BBVA，从试用走向组织采用	52
第 23 章 TIME，在固定期限内交付	54
第 24 章 GitLab，区分产品与内部应用	56
第 25 章 Assembled，客服系统的韧性	58
第 26 章 Klarna，自动化指标的边界	60
第 27 章 Datawhale，从具体业务开始	62

第一篇 认识 FDE

先理解工作与责任，再判断什么问题值得解决。

第 1 章 FDE 的工作与责任

第 2 章 用业务流程理解问题

第 3 章 价值指标与成本

第 4 章 能力地图与协作边界

第 1 章 FDE 的工作与责任

一个 AI 项目会经过很多人。业务负责人提出目标，采购购买服务，工程师接入模型，安全团队检查数据去向，一线人员决定是否继续使用。FDE 要让这些工作在同一个项目里接得上。

从工作边界理解岗位

FDE 通常参与问题发现、方案设计、系统构建和生产交付。能否写代码很重要，但单凭编码能力无法定义这个岗位。判断一份工作是否具备 FDE 特征，更有用的办法是看工程师能否接触真实用户，能否改变不合理的方案，以及上线后是否继续跟踪结果。

售前工程师可能在签约前完成技术验证；实施团队可能把成熟产品配置到客户环境；产品工程师可能持续维护一个模块。这些工作都有价值，也可能与 FDE 重叠。职责名称由公司决定。项目开始时，应确认发现、构建、验收和运营分别由谁负责。

工作问题	FDE 需要留下的结果
用户到底在做什么	可核对的任务记录与现状流程
做到什么算有效	基线、目标与不可恶化指标
怎样接入客户系统	数据、权限、接口与失败处理方案
谁接着维护	明确的业务负责人和技术负责人

靠近现场的工程判断

企业的制度文件会告诉你流程应该怎样运行，系统接口会告诉你数据怎样流动。现场观察还会暴露另一部分工作。有人靠本地表格修正编码，有人凭经验判断异常。每天复制同一段文字，也可能占去不少时间。这些动作解释了为什么已有软件仍然没能解决问题。

工程师接近现场以后，可以更早判断哪些步骤值得自动化。规则已经清楚、输入也结构化的任务，可以先用普通程序。需要理解材料、总结证据或处理模糊语言的环节，再评估模型。能够说清楚为什么不用模型，也是 FDE 的技术判断。

交付责任需要边界

对结果负责不等于一个人承担全部责任。医院的临床决策仍由获授权人员作出，退款权限仍受客户政策约束。FDE 应把权限和责任写入系统，不能接受「让 AI 自己决定」这样没有边界的要求。

项目结束时，除了能工作的应用，还应留下评测集、运行记录、操作说明和维护人。工程师离开后，客户能够继续处理常见问题，才说明交接完整。

本章练习

找一份公开 FDE 招聘说明，分别标记发现、编码、客户协作、上线和产品反馈五类职责。再写下它没有说明的内容，例如出差、值班、项目并行数或维护周期。把未知项变成面试问题，不根据岗位名称猜测。

延伸阅读

- [OpenAI 的 FDE 职责](#)
- [Palantir 的平台入门与工程协作](#)

第 2 章 用业务流程理解问题

「做一个客服 Agent」已经包含了方案，却没有解释为什么要做。开始构建以前，先把客户正在处理的任务写出来。这样才能比较 AI、普通自动化和流程调整三种办法。

一项任务的完整描述

任务从一个触发事件开始。用户收到咨询、订单进入异常状态、设备发出告警，都可能触发后续工作。随后有人读取信息，作出判断，调用系统，再把结果交给下一位参与者。

记录流程时，至少写清触发条件、参与角色、输入资料、判断规则和最终输出。还要记录失败后的处理办法。只画成功路径，会漏掉最消耗人工的部分。

要观察的地方	要留下的证据
等待	等谁、等什么、等待起止时间
重复录入	相同字段出现在哪些系统
人工判断	判断依赖什么信息与经验
返工	错误何时被发现、由谁修正
例外	哪些情况不能按标准规则处理

区分工作量与限制条件

某一步花费很多时间，不一定是整条流程的主要限制。文书生成快了，审批仍然需要数天，端到端周期可能几乎不变。观察时应把执行时间与等待时间分别记录。

同样，自动化容易处理的任务，未必值得优先做。若一项任务每月只发生一次，维护成本可能超过收益。若它涉及不可逆写入，即使频率很高，也需要先解决权限和复核问题。

本书建议先选择一个高频、有明确所有者、可以取得样本的任务。它应当足够窄，能被完整测量；也应当连接真实工作，用户愿意继续使用其结果。

把人的动作和系统动作分开

流程图可以分成两条线。人的一条线记录阅读、判断、确认和交接；系统的一条线记录查询、计算、写入和通知。两条线相交的地方，就是界面和权限设计的重点。

如果一个结果需要人工确认，界面就必须给出足够证据。只显示「建议通过」不够，复核者还需要知道依据、缺失信息和影响范围。若系统自动发送通知，则要明确收件人、发送时机和重复发送的处理方式。

本章练习

选择自己能合法观察的一项工作，完整记录一次正常处理和一次异常处理。不要先画理想流程。把真实动作整理成一页图，再标出最希望改变的一个环节。交给实际操作者确认，直到对方能够按图复述工作。

延伸阅读

- [Palantir 用例界定学习入口](#)

第 3 章 价值指标与成本

模型回答得更好，只能证明输出质量发生变化。项目是否值得继续，还要看用户完成了什么工作，以及组织是否获得足以覆盖投入的收益。

把指标接起来

模型指标用于定位系统质量，产品指标说明用户怎样使用，业务指标反映任务结果。三者需要有明确联系。例如知识问答的引用正确率提高以后，用户是否减少了查证时间，最终是否更快完成任务，都需要另行测量。

层次	可选指标	常见误读
模型	字段正确率、引用支持率、工具参数有效率	总分高就可以上线
产品	任务完成率、复核时长、人工接管率	登录即代表采用
业务	处理周期、返工率、损失、服务质量	节省时间可直接当利润

先选一个主要目标，再设置不能恶化的指标。减少客服处理时间时，重复咨询、错误退款和投诉可能都是约束。它们应与速度一起出现在试点报告中。

先测量原有流程

上线前留下当前处理时间、样本范围和错误类型。平均值有用，但很慢的少数任务也可能决定用户体验。按任务复杂度分别统计，通常比把全部任务混在一起更容易解释变化。

试点期间如果工单变简单了、人员变多了或政策调整了，结果就不能全部归因于 AI。条件允许时可以设置同期对照；条件不允许时，至少保留这些变化并限制结论。

一笔算得清楚的账

本书建议用下式做内部讨论，实际金额由组织自行核对。

净收益 = 可归因的新增收入或节省支出 - 建设支出 - 持续运行支出。

持续运行支出包括模型、存储、监控、人工复核、支持和更新。工程团队常把复核时间漏掉。如果用户为了确认结果又完成了一遍原有工作，表面自动化率再高，也可能没有节省时间。

释放出的工作时间可以改善服务、增加产能或减少加班。只有组织确实作出相应安排，才能进一步讨论财务价值。报告中应分别列出时间变化和已兑现的支出变化。

本章交付物

写一页试点衡量表，包含目标任务、基线、目标值、统计周期、样本来源、约束指标和负责人。每个百分比都要能回答分母是什么。暂时没有基线的项标明待测量，不填估计数字充当事实。

延伸阅读

- [BBVA 的采用与效率口径](#)
- [Klarna 的早期客服指标](#)

第 4 章 能力地图与协作边界

FDE 会接触业务、软件、数据和组织协作。学习时很容易把自己需要掌握的工具列成无限长的清单。更实用的办法是从交付动作反推能力。

五种可以检验的能力

业务理解可以通过一张被用户认可的流程图检验。工程能力可以通过一条真实可运行的请求链路检验。数据判断要看你能否发现缺失、冲突和权限问题。评测能力要看错误能否被稳定复现。协作能力则要看跨部门决定是否有明确责任人与记录。

这些能力不要求平均发展。后端工程师可能先补用户观察和采用设计，业务顾问则需要补接口、数据库、测试与部署。选择自己的一个短板，用可交付的作品练习，比继续收集术语更有效。

能力	最低可见作品
业务理解	一页现状流程与问题说明
工程实现	可复现的应用、测试与部署说明
数据判断	字段定义、质量检查和权限范围
评测改进	失败分类、测试集、版本比较
协作交接	决策记录、运行手册和维护责任

知道何时请专业人员参与

了解安全概念不等于能够批准安全例外。懂一些财务指标不等于有权签署财务结论。FDE 的能力包含识别这些边界，并及时让相应负责人参与。

对每个重要决定，写下提议人、执行人、批准人和受影响的人。角色可以重叠，但批准权必须清楚。项目越接近写入生产系统，越不能依赖口头理解。

技术深度怎样生长

先把一条小流程做完整，再沿着暴露的问题深入。查询慢，就学习索引与缓存；权限复杂，就学习授权模型；模型经常引用错误，就检查检索与评测。这样的技术积累有具体问题作为检验。

本书不建议把熟悉框架数量作为能力指标。框架能帮助完成工作，也可能掩盖请求、状态和错误处理。至少选择一个项目，能够不依赖框架术语讲清楚它怎样运行。

本章练习

给自己的五种能力各选一个现有作品作证据。没有作品的项目不必打高分，直接写出下一次练习。再请一位与你背景不同的人审阅，看看你是否遗漏了对方最关心的责任。

延伸阅读

- [Hugging Face Agents Course](#) 的实践要求

第二篇 技术基础

把模型、数据与工具放进可以验证的系统。

第 5 章 大模型与上下文

第 6 章 数据、接口与业务对象

第 7 章 RAG 与企业知识

第 8 章 工作流、Agent 与 MCP

第 9 章 评测与错误分析

第 10 章 权限、安全与人工控制

第 5 章 大模型与上下文

进入企业项目，首先要弄清一次模型调用获得了什么信息。用户看到的是一个回答，工程师需要看到指令、输入、历史、工具结果和输出约束。

一次调用的组成

模型根据输入上下文生成输出。上下文可以包含任务指令、用户问题、检索资料、示例和工具返回值。模型没有收到的企业事实，不能指望它准确补出。模型自身掌握的知识也可能过时，或不适用于当前组织。

Token 是模型处理文本的计量单位，不能简单等同于汉字或英文单词。上下文窗口限制单次可处理的信息规模，输出长度还有自己的约束。应用需要管理资料数量、重要性和位置，而非持续堆入全部历史。

提示写清什么

一份可维护的提示至少交代任务、输入含义、输出形式、判断规则和信息不足时的行为。示例用于说明难以只靠文字表达的边界。给模型写一长段职业身份介绍，通常不能替代具体规则。

提示应与代码一样保留版本。调整提示时，用同一批样本比较质量、时延和成本。若只保留几次令人满意的回答，团队无法判断修改是否改善了总体表现。

结构化输出的边界

让模型返回结构化字段，可以减少程序解析的歧义，但字段符合格式不代表事实正确。订单编号可能格式合法却不存在，金额可能是数字却超出允许范围。应用应继续验证存在性、业务约束和当前权限。

同样，模型表达的确信程度不能直接当作正确概率。需要通过真实样本校准，或使用明确规则决定何时拒答、补问或交给人工。

上下文需要取舍

过时规则与现行规则同时出现时，应由数据版本和业务政策决定优先级。不要把冲突材料交给模型以后期待它自动理解公司的生效安排。上下文管理的一项重要工作，就是在调用以前排除不应进入的信息。

本书建议先做最小可用上下文，再逐步增加证据。每加一类资料，都检查它是否改善了目标任务，是否引入泄露、干扰或更高成本。

本章练习

为同一个抽取任务准备三版输入，分别包含充分证据、缺失证据和冲突证据。写出每种情况下的期望行为。测试重点放在模型是否识别信息不足，而非回答是否流畅。

延伸阅读

- [Anthropic 关于工作流与模型调用的工程说明](#)
- [Hugging Face 的 Agent 基础课程](#)

第 6 章 数据、接口与业务对象

模型应用进入企业后，经常先遇到数据问题。同一个客户有多个编号，同一项金额有不同计算口径，历史记录缺少状态。连接成功只是第一步，理解数据含义才决定后续结果是否可信。

先定义业务对象

订单、设备、工单、合同都可以成为业务对象。每个对象有身份、属性、状态和关系。订单关联客户与商品，工单关联订单与处理人。把这些关系写清楚，比先选择数据库更有帮助。

Palantir 的 Ontology 是把数据与业务对象、操作相联系的一种平台实现。学习时可以借此理解对象建模，但不应把特定产品的概念当成所有系统必须采用的架构。

数据问题	进入模型前的处理
名称不同但对象相同	建立标识映射与别名
单位或时区不一致	统一表示并保留原始值
历史规则已失效	记录生效时间与版本
资料缺失	标出缺失，不擅自补全
用户看不到部分记录	查询时执行访问控制

API 是一份行为约定

接口需要说明输入、输出、错误和副作用。一个「更新订单」工具若同时改状态、发通知和触发财务操作，模型或调用者就难以判断影响。尽量把高风险动作拆成语义清晰、权限独立的接口。

读取接口和写入接口应分开设计。读取失败通常可以重试，写入超时则可能存在「已经成功但响应丢失」的情况。再次提交前需要通过业务流水号或幂等标识核对，避免重复扣款、退款或发单。

身份应沿请求传递

应用知道用户是谁，并不代表下游服务知道用户能做什么。把所有请求交给一个全权限账户执行，会使用户权限失去意义。服务端应根据受信任的身份信息检查租户、对象和动作权限，不能接受模型自填的用户身份作为授权依据。

日志也属于数据系统。它可能记录客户输入、检索片段和工具参数，因此同样需要访问权限、保留期限和脱敏处理。

本章交付物

选一个业务对象，完成字段字典与接口说明。每个字段写清来源、类型、允许值、更新时间和访问范围。再为每个写操作列出副作用、重复提交的处理办法及人工核对方式。

延伸阅读

- [Palantir 的数据层与对象层入门](#)
- [MCP 的接口与上下文交换架构](#)

第 7 章 RAG 与企业知识

RAG 是检索增强生成。应用先从允许访问的资料中找出相关证据，再让模型根据证据回答。它适合资料会更新、答案需要出处的任务，但效果依赖整条数据处理过程。

从文档到证据

基本过程是收集与授权、解析、切分、建立索引、检索、排序，再生成答案与引用。每一步都可能改变结果。扫描件识别错了一位数字，检索再准确也无法恢复原始事实。

切分时要保留理解片段所需的背景。孤立的一行表格可能缺少列名，条款可能缺少适用范围。片段应关联文档标题、章节、版本、日期和权限。补充背景可以帮助检索，但补充内容也需要检查，不能悄悄改变原文含义。

检索方法按任务比较

关键词搜索擅长精确名称、编号和专业术语；向量检索擅长表达不同但语义接近的查询。混合检索与重排序可以作为候选方案，用真实问题比较后决定是否采用。

不要只测答案。先看正确资料是否进入候选结果，再看它是否被排在可用位置，最后检查模型是否正确使用。若第一步已经失败，继续修改回答提示通常不会解决问题。

失败现象	优先检查
完全找不到资料	是否入库、解析是否完整、权限是否正确
找到同名旧文件	版本、生效时间与排序
引用存在但不支持结论	片段完整性和答案证据匹配
不同用户看到相同敏感内容	检索过滤、缓存隔离与引用权限

知识需要维护人

每类重要资料都应有所有者。新增、修订、撤回和失效需要明确流程。删除或撤回源资料时，索引、缓存和引用也要按组织政策同步处理，避免旧内容继续出现在回答中。

没有足够证据时，可以展示检索结果并提示无法得出结论。拒答不必意味着页面什么都不提供，但不能为了完整感而编造规则。

本章练习

建立一组包含编号查询、口语查询、过期规则和越权问题的测试集。分别记录检索命中、引用正确和答案可用三项结果。先修复最前面失效的一步，再比较整体表现。

延伸阅读

- [Anthropic 的 Contextual Retrieval 说明](#)

第 8 章 workflows、Agent 与 MCP

一个应用可以使用模型，却不需要让模型决定所有步骤。把流程控制交给谁，是工程设计中必须明确的选择。

固定工作流与动态决策

工作流由程序预先安排步骤。例如先识别单据，再校验字段，最后交给人工确认。Agent 则可以根据当前结果决定下一步动作，例如先查询订单，发现缺少配送信息后再调用物流工具。

Anthropic 的工程文章采用这一划分，并建议从简单、可组合的方法开始。它适合解释设计取舍，不能被理解为一种必须追求更高自主性的成熟度排名。

任务条件	可先考虑的方案
规则确定、字段明确	普通程序与规则引擎
步骤固定、部分步骤需要理解语言	带模型节点的工作流
路径随输入变化、结果可以检查	有边界的 Agent
多个独立子任务且收益可验证	并行或多 Agent，额外评估协调成本

工具决定行动范围

工具说明要让调用者知道何时使用、需要什么参数、返回什么，以及会改变什么状态。给 Agent 一个可任意执行的通用接口，往往会把本来能够限制的风险放大。

控制至少包括调用次数、总运行时间、费用预算和写入权限。停止条件要由程序执行，不能只在提示里要求模型自觉遵守。外部页面和工具返回内容都可能含有不可信指令，不能自动升级为系统授权。

MCP 解决连接约定

MCP，即 Model Context Protocol，规定 AI 应用与外部服务交换上下文和调用能力的方式。常见角色包括宿主应用、客户端和服务端。服务端可以提供工具、资源与提示模板。

协议统一了部分连接方式，但不会自动替应用选择正确工具，也不会替企业完成权限设计和安全审查。接入一个服务端以前，仍要核对它能访问的数据、能执行的动作、凭据范围和维护来源。协议版本变化较快，实施时应使用当前官方文档。

本章练习

为一个只读查询任务设计两个工具。每个工具写出参数、结果、错误和权限。再加入一个写工具，说明它为什么需要确认，以及用户取消后系统应保留什么状态。最后检查是否能用固定 workflow 更简单地完成同一任务。

延伸阅读

- [Anthropic 的工作流与 Agent 设计](#)
- [MCP 官方架构说明](#)

第 9 章 评测与错误分析

评测让「这个结果可不可以用」变成能够重复检查的问题。它需要业务人员参与，因为工程师未必知道哪些错误只影响表达，哪些会导致实际损失。

从样本写出规格

一条评测样本包含输入、必要上下文、期望行为、不可接受行为和评分规则。答案不一定只有一种写法，因此可以按事实、完整性、行动和风险分别评分。

样本应覆盖高频任务、边界情况和历史失败。开发集用于调试，保留集用于检查是否只适应了已见过的问题。生产反馈可以补充样本，但需要去除不必要的个人信息，并遵守数据使用授权。

评分器各有适用范围

格式、必填字段和参数范围可以用程序检查。事实是否正确、政策是否适用，可能需要专家判断。模型评分适合扩大检查规模，但应与人工标注比较，确认它会漏掉哪些错误。

仅看平均分会掩盖少数高风险问题。把不同语言、任务类型、权限级别与异常条件分开报告。当总体成绩提高但高风险任务退化时，团队应按预先约定的规则决定是否发布。

先找到错误发生的位置

错误类别	可能的工程动作
输入缺信息	补问或改变数据采集
证据未检索到	修复索引、查询或权限
模型误用证据	改提示、样例与证据展示
工具参数错误	强化接口约束和参数校验
写入重复	幂等处理与状态核对
用户误解结果	调整界面、标签和确认步骤

换模型可以作为实验，但应先有错误分类。否则更好的总分可能只是暂时掩盖了数据或接口问题。

把评测接入发布

模型、提示、工具定义、检索配置和政策变更都可能影响结果。发布报告应保留这些版本，并与上一版比较质量、延迟和成本。失败样本可以链接到具体修改，方便后来的人理解取舍。

Morgan Stanley 的公开案例把领域评测放进开发过程。它说明企业应用能够将专家标准转成持续测试，但其具体样本与阈值不能直接套到另一家公司。

本章交付物

建立一个小型测试集，故意放入至少一种严重错误。用程序检查与人工检查各跑一遍，比较二者差异。报告不仅列总分，还应能定位每个失败以及它对应的修复动作。

延伸阅读

- [Morgan Stanley 的评测实践](#)
- [Arize 的 Agent 评测说明](#)

第 10 章 权限、安全与人工控制

当模型只能生成建议时，错误主要通过用户采纳影响工作。模型获得工具之后，错误可能直接改变记录或触发外部动作。控制措施应跟着这种影响变化。

按动作判断风险

读取公开资料、读取敏感数据、草拟内容、修改内部记录和对外执行，风险并不相同。应用应针对每一种动作定义授权与确认。不能因为用户可以打开应用，就允许它代表用户完成所有操作。

高影响动作要在执行位置设置控制。确认界面应显示对象、金额或范围、预期变化和是否可撤销。若用户看不到这些信息，确认按钮只能留下形式上的记录。

提示注入的信任边界

网页、文档、邮件和工具结果都可能夹带要求模型忽略规则或传出信息的内容。这些材料是待处理数据，不能赋予它们与用户授权相同的地位。

防护需要多层配合。限制工具权限、校验参数、隔离敏感数据、控制外部发送目标，以及记录高风险动作，都能缩小影响。单独加一句「不要受恶意指令影响」无法替代这些工程控制。

人工复核需要工作条件

复核者要获得证据、足够时间和拒绝权限。若每天要确认大量无法核查的结果，人工控制容易退化成机械点击。系统应把需要判断的差异呈现出来，并允许回到原始资料。

控制问题	应有的明确答案
谁能读取	用户、角色、租户与对象权限
谁能执行	动作授权、额度和确认条件
何时停止	异常、缺证据、预算耗尽等条件

控制问题	应有的明确答案
出错后怎么办	接管人、暂停方式和记录核对
数据保留多久	内容分类与组织保留政策

安全验收应包含失败路径

测试越权查询、跨租户访问、恶意文档、参数篡改和重复提交。检查失败时是否泄露敏感细节，是否仍然产生了副作用。安全团队给出要求后，应把可自动检查的部分纳入持续测试。

本章仅提供工程检查思路。具体行业、地区与合同要求，需要组织的专业人员审核。没有通过对应审查，不能声称应用已经合规。

本章交付物

为项目列出一份动作权限表和失败测试表。选一个最高风险动作，完整演练用户拒绝、请求超时与人工接管，确认系统状态可以解释。

延伸阅读

- [OWASP 的大模型应用风险项目](#)

第三篇 交付实务

从现场观察到生产运行，把结果交到能够继续维护的人手里。

第 11 章 需求发现与现场访谈

第 12 章 范围与验收约定

第 13 章 原型与受控试点

第 14 章 生产发布与回退

第 15 章 可观测性与故障处理

第 16 章 用户采用与运营交接

第 17 章 团队组织与复用

第 18 章 学习路线与作品集

第 11 章 需求发现与现场访谈

需求发现的结果应当让团队能够决定下一步验证什么。会议记录有用，但还需要任务样本、流程、基线与关键未知项。

请用户带来一次真实任务

访谈可以从最近完成的一次工作开始。请对方展示允许公开的输入、操作过程和最终结果。询问在哪一步需要停下来查资料，哪一步必须请同事帮忙，以及做错以后怎样发现。

不要只与项目发起人交谈。一线用户知道实际动作，流程负责人知道规则和资源，安全与 IT 人员知道接入条件，预算负责人知道项目为何值得投入。各方说法不同，往往反映了不同责任，无须急着把它们压成同一个答案。

观察与解释分别记录

「用户复制了三个系统的编号」是观察，「接口缺失导致工作慢」是解释。解释需要继续验证。也许存在接口，只是用户没有权限；也许编号不一致，连接接口也无法直接匹配。

访谈结束后，把事实、假设和待验证问题分栏整理。涉及个人数据或商业机密时，记录必要信息即可，不应为了完整而扩大采集范围。

发现阶段的出口

材料	能回答的问题
问题说明	谁在什么任务上遇到什么障碍
当前流程	人、数据和系统怎样协作
正常与失败样本	好坏结果怎样识别
基线记录	当前耗时、质量与成本怎样
依赖清单	权限、接口和负责人是否就绪
验证计划	下一步先检查哪个假设

如果关键数据拿不到、业务负责人不愿投入时间，或结果无法判断，团队应先解决这些条件。进入开发不会让这些问题自行消失。

本章练习

用一次短访谈获取一个正常样本和一个异常样本。访谈后写一段不含工具名的问题说明，再请受访者修正。检查双方是否同意项目要改变的那一步工作。

延伸阅读

- [Palantir 的用例界定课程入口](#)

第 12 章 范围与验收约定

原型开始以后，新需求通常会继续出现。范围管理让这些变化可见，避免团队在不知不觉中承担另一项工作。

选一条足够窄的完整流程

可以限制用户群、任务种类、地区或工具数量，但应尽早贯通身份、数据、处理、结果和日志。只把模型环节做得很精致，无法证明客户环境里整条流程能够运行。

把功能分成四类，本期完成、试点中由人工承担、后续评估和明确不做。人工承担的部分要写进演示与验收说明，不能把幕后人工包装成自动化能力。

验收前先约定证据

验收条件要同时包含功能、质量、风险和运营。谁提供样本、谁判断争议、在哪个环境测试，都要提前说明。如果上线日期固定，范围就需要容许调整；若质量约束不可降低，则不能以日期为理由略过测试。

约定项	示例形式
目标任务	限定用户处理限定类型记录
范围边界	查询与草拟可用，外部发送由人确认
质量证据	约定样本集、评分规则与严重错误项
运行证据	权限测试、监控、回退与支持演练
接受决定	指定业务与技术验收人

这里的形式是本书建议。具体目标数值必须根据风险、当前基线与资源确定，不能把别的项目阈值当成通用标准。

变更怎样进入项目

每项变更记录理由、影响、依赖与决定。新增写操作可能改变安全审核范围；增加语言可能需要新的专家样本；更换数据源可能影响接口和索引。负责人据此选择调整时间、资源或范围。

对无法及时解决的关键依赖，写明暂停或转向条件。项目停止也应留下发现结果和可复用材料，使后续团队知道哪些假设已经被检验。

本章交付物

制作一页交付约定，写出任务、范围、验收证据、双方责任、变更办法及退出条件。让一名未参加项目的人阅读，检查他能否判断哪些事情不在本期承诺中。

第 13 章 原型与受控试点

原型用于降低不确定性。开始以前，先写下最可能使项目失败的假设，再选择能检验它的最小实验。

原型可以有不同形态

如果问题是用户是否能理解引用，先测试结果页面。如果问题是历史资料能否解析，先跑文档样本。如果问题是写接口是否稳定，就在授权测试环境验证调用。完整聊天框未必是最先需要的部分。

阶段	能检验什么	不能据此声称什么
人工辅助演示	工作价值和交互理解	已经完成自动化
离线测试	模型与流程在样本上的表现	已适应生产流量
影子运行	实际输入下的表现	已产生业务收益
受控试点	有限范围内的真实使用	可以无条件全量推广

每次进入下一阶段，都应新增一项证据。阶段升级同时意味着更大的数据和操作责任，需要对应授权。

让用户实际完成任务

试用时观察用户会不会核对、修改、复制或放弃结果。只询问是否喜欢，容易得到礼貌但无用的反馈。把用户修改分成事实修正、规则修正、表达调整和个人偏好，有助于后续评测。

记录实验条件，包括样本、模型、提示、工具和参与者。一次结果变好后，先确认变化来自哪里。多个因素同时修改，会使团队难以解释改善是否可重复。

试点要留出人工退路

当系统无法完成任务，用户应知道怎样继续工作。接管时保留已经核实的信息、失败原因和待处理动作，避免让用户重新讲述全部背景。

扩大试点前检查质量是否跨用户稳定、复核是否过重、支持人员能否承接问题。低使用率需要回到真实工作观察，不能一律解释为用户缺少培训。

本章练习

写一张实验卡，包含假设、验证办法、成功与停止条件。完成一次小实验后，保留一个失败样本，并解释它怎样改变了下一步设计。

延伸阅读

- [TIME 的公开交付案例](#)

第 14 章 生产发布与回退

生产发布会把应用放进持续运行的业务环境。用户数量、数据分布与故障后果都可能超出原型条件，因此上线需要独立的检查。

一次发布包含哪些版本

代码之外，模型、提示、工具说明、索引和政策都可能改变行为。发布记录要能识别这组配置，出现问题时才能定位和恢复。只记代码提交号，常常无法复现当时的回答。

模型供应商更新、文档自动同步与权限调整也应有变更监测。外部条件变化后，核心评测需要重新运行。

逐步扩大影响范围

发布单位可以是指定用户、任务类型或流量比例。先选择风险可控且反馈及时的群体，设定观察窗口和暂停条件。扩大范围由实际证据决定，不只由计划日期决定。

上线检查	需要看到的证据
功能与质量	关键任务测试和风险切片结果
数据与权限	真实身份下的访问与越权测试
性能与费用	预期负载和费用上限测试
运行支持	监控、值班联系人与升级路径
回退	实际演练过的暂停和恢复办法

回退不能撤销一切

切回旧模型或旧代码，不能自动撤回已经发出的邮件、已修改的订单或已形成的客户承诺。写操作需要单独的核对与补偿方案，并由获授权人员决定是否执行。

因此，回退计划要分开两件事。先停止继续产生影响，再确认已经发生的变化。事故记录保留受影响对象、动作时间和当前状态，便于业务负责人处理。

本章交付物

完成一份发布记录与回退演练记录。模拟模型质量下降、工具不可用和权限异常，检查团队能否在不依赖原开发者的情况下暂停相关功能，并继续办理必要业务。

延伸阅读

- [Google SRE 的监控原则](#)

第 15 章 可观测性与故障处理

用户报告「结果不对」时，工程师需要把一次任务还原到具体步骤。可观测性提供这种还原能力，同时也要控制记录内容带来的隐私风险。

记录可解释的一次请求

为一次任务分配关联标识，把检索、模型调用、工具执行和人工接管联系起来。记录开始结束时间、状态、版本和必要的输入输出摘要。不要无差别保存敏感全文，也不必要求模型暴露隐藏的内部推理过程。

运行记录应使团队能够区分响应慢、请求失败、模型答错与业务处理失败。服务返回成功，并不意味着订单已正确更新或用户问题已解决。

监控用户能感受到的结果

Google SRE 的监控材料讨论延迟、流量、错误与饱和度。模型应用可以保留这些服务指标，再增加引用错误、工具失败、人工接管和任务完成情况。每个告警最好对应一个能采取行动的人与处理办法。

故障	保守处理方式
模型超时	有限重试，随后提供人工或非模型路径
写工具超时	先核对状态，再决定是否重试
检索不可用	显示限制，不编造无证据答案
费用异常	限制流量、检查循环与调用预算
质量突降	暂停高风险功能并回放失败样本

备用模型也需要验证

接口兼容不保证行为一致。备用模型的结构化输出、工具参数、拒答与政策遵守情况都需要测试。切换时可以先关闭高影响操作，提高人工参与比例，等关键指标稳定后再恢复。

事故复盘记录触发条件、时间线、影响范围、恢复动作和预防改动。重点是让相同故障更早被发现、影响更小，并留下可重复的测试。

本章练习

选择一个可安全模拟的依赖故障，观察系统是否在预算内停止。检查用户看到的提示、日志里的信息和人工接管材料是否一致。演练不得影响真实客户或触发未授权写入。

延伸阅读

- [Google SRE 监控章节](#)
- [Assembled 的公开故障切换案例](#)

第 16 章 用户采用与运营交接

系统上线之后，用户仍可能回到旧办法。要判断原因，需要观察实际工作中增加和减少了哪些动作。

使用入口影响采用成本

如果用户必须离开原系统、重新输入上下文，再把答案复制回去，节省的时间可能被这些动作抵消。尽量复用已有身份与工作入口，同时保持结果来源和当前状态可见。

信任来自持续可用的结果，也来自用户知道系统何时会失败。展示证据、标明信息缺口、允许修改与申诉，都有助于形成合理预期。用宣传替代质量，只会使下一次错误更难处理。

用真实任务判断采用

登录数能说明接触范围，不能证明工作改变。观察完成了多少任务、多少结果被修改、用户在哪里放弃，以及复核耗时是否下降。可以按部门、岗位和任务类型分开比较。

试点用户应包含愿意指出问题的人。他们可以帮助解释使用方法，但不应承担全部技术支持。身份异常、权限变化、模型故障和政策更新需要正式处理渠道。

把维护能力交给客户

交接对象	应能独立完成的工作
业务负责人	判断质量、调整允许任务、决定暂停
内容负责人	更新资料、处理冲突、撤回过期内容
技术负责人	查看运行状态、发布、恢复与排查
支持人员	收集问题、分类、升级并反馈结果

交接应通过一次实际演练检验。让维护人完成更新与回退，让支持人员处理一个模拟问题。说明文档能够被找到、读懂并用起来，才算真正交付。

本章练习

记录用户完成一项任务的全部操作，计算新系统额外增加了哪些步骤。再让一位未参与开发的人按运行手册处理一个小故障，补齐他无法继续的地方。

延伸阅读

- [BBVA 的企业采用案例](#)
- [Datawhale 制造业培训实践](#)

第 17 章 团队组织与复用

单个项目可以依靠少数人熟悉全部细节。项目数量增加以后，这种方式容易让支持、定制与交接相互挤占。团队需要决定哪些工作留在客户现场，哪些进入共享产品。

先划清共同责任

业务负责人确认价值与规则，FDE 负责跨系统构建与交付协调，平台团队维护共享服务，安全与运营人员负责相应控制。团队规模不同，一人可以兼任多个角色，但每项重要责任都要有人明确接受。

排期时应把上线后的支持计入工作量。若每位工程师同时启动多个项目，却没有维护容量，旧项目的故障会不断打断新项目。

哪些东西值得复用

身份接入、日志规范、工具接口、评测流程和发布检查通常容易形成共享能力。客户特有的政策、审批和数据定义则需要保留配置或扩展边界。

看到第二个相似需求时，可以先比较差异，再决定是否抽象。过早把一个客户的特殊流程做成平台规则，会让后来项目绕着错误假设工作。

候选内容	进入共享能力前要检查
连接器	身份、租户隔离和接口版本
工具封装	行为语义、权限与错误处理
评测集结构	可复用格式与客户数据隔离
交付模板	必填项、适用条件和责任人
产品功能	多个项目是否具有相同需求

项目经济性需要完整记录

除了建设时间，还要记录售前验证、集成、返工、培训和后续支持。若收入增长同时带来同样比例的人工支持，组织仍需面对服务成本。

可以定期比较各项目的定制工作量、交付周期、支持负担和共享组件使用情况。复用率也不能单独作为目标，复用了不适用的组件可能增加后续返工。

本章交付物

从一个已完成项目里选出三项候选复用材料，分别写明适用条件与不可复用部分。至少保留一个明确不抽象的客户特例，并解释这样做怎样减少误用。

延伸阅读

- [Palantir 的平台与开发者资料](#)

第 18 章 学习路线与作品集

学习 FDE 可以围绕一项小型交付展开。课程提供概念和练习，作品则检验你能否处理需求、数据、失败和交接。两者需要结合。

按缺少的能力选择课程

下列入口在本次编写时已核查。课程开放方式、费用、账号与证书条件可能变化，应以官方页面为准。本书不承诺就业或认证结果。

学习目的	官方资料	学完后应留下什么
业务对象与用例界定	Palantir AIP 入门与 Scoping Use Cases	一页用例与对象关系图
理解 Agent 的运行方式	Hugging Face Agents Course	带工具与停止条件的小应用
选择简单工作流	Anthropic 工程文章	一份架构取舍说明
调试与评测 Agent	DeepLearning.AI 与 Arize 课程	测试集、评分器与实验报告
理解接口连接	MCP 官方文档	工具接口与权限说明

Palantir 的入门路线连接用例界定与实际工作流，适合学习平台如何服务业务。Hugging Face 课程包含框架和实践任务，适合具备基础 Python 能力的读者。DeepLearning.AI 的评测课程覆盖可观测性、组件评测与结构化实验。只完成其中一项，仍不足以证明可以独立交付生产系统。

一条可调整的学习安排

第一阶段观察真实任务并取得合法样本，留下流程、基线与权限范围。第二阶段完成最小应用，把数据、检索或工具调用接起来。第三阶段建立测试与运行记录，故意模拟失败。最后请其他人试用，并完成交接说明。

可以按自己的可用时间安排，不必把某个固定天数当作能力保证。每一阶段的出口由作品决定。应用能够运行但没有评测，就继续补评测；演示顺利但用户无法自行使用，就继续改交互和说明。

作品集应该让人核查

一份有说服力的作品集包括问题背景、授权范围、方案取舍、运行方法、失败样本和结果限制。演示视频可以辅助理解，但要说明哪些部分为模拟数据，哪些已经实际验证。

公开发布时，不上传客户数据、凭据、私人会议或未授权材料。可以用明确标注的合成数据展示技术流程，但不能据此声称取得了真实业务收益。

怎样使用 X 与社区

X 适合发现招聘、工程师讨论和新材料。本次检索到 Speechmatics 发布过包含 FDE 的岗位信息。这能作为岗位线索，不能用于推算行业规模或平均薪酬。看到效果数字后，应继续寻找公司原文、技术说明或正式文件。

国内实践可从 Datawhale FDE100 开始。范冰的公开 FDE 指南也值得作为延伸阅读，但其版权声明限制商业用途。本书只链接原作。

本章交付物

把学习计划改写成四次可展示的提交，每次说明新增了什么能力和证据。最后请别人从空白环境复现项目，记录他遇到的问题并修正。

延伸阅读

- [Palantir AIP 学习路线](#)
- [Hugging Face Agents Course](#)
- [DeepLearning.AI 的 Evaluating AI Agents](#)
- [Anthropic 的 Agent 工程文章](#)
- [MCP 官方文档](#)
- [Speechmatics 的 X 招聘帖](#)
- [Datawhale FDE100](#)
- [范冰的 FDE 指南](#)

第四篇 案例拆解

用公开事实检查方法，保留分析边界与未知项。

第 19 章 Airbus，让数据进入维修决策

第 20 章 Tampa General，医院运营协同

第 21 章 Morgan Stanley，把评测放进开发

第 22 章 BBVA，从试用走向组织采用

第 23 章 TIME，在固定期限内交付

第 24 章 GitLab，区分产品与内部应用

第 25 章 Assembled，客服系统的韧性

第 26 章 Klarna，自动化指标的边界

第 27 章 Datawhale，从具体业务开始

第 19 章 Airbus，让数据进入维修决策

航空运营把设备、维护记录与人的判断联系在一起。Skywise 适合放在案例篇开头，因为它提醒读者，FDE 的 engineered work 早于本轮大模型应用，也不局限于聊天界面。

公开事实与证据

Airbus 在 2017 年发布 Skywise，公开介绍了与 Palantir 合作的数据平台。平台将航空公司运营、维修与飞机相关资料联系起来，支持航空运营与维护分析。早期材料列出 AirAsia、Delta、easyJet 等采用方。

证据等级为 A，来自企业发布材料。不同年份的采用规模与收益数字属于不同范围。本章不把它们合并成统一效果，也不把平台部署全部归因于某个岗位。

业务问题怎样形成工程问题

维修判断涉及具体飞机、部件、故障记录与处理状态。不同系统中的名称和时间不能正确对应，分析人员就难以判断资料是否描述同一事件。能够连接数据，只解决了传输；业务对象和关联关系决定了数据能否一起解释。

下面是本书的分析与教学设计，证据等级为 D，并非对客户内部架构的披露。

若为类似任务设计试点，可以选择一种设备和一种异常。先整理历史记录的标识、时间与维修结果，再请专业人员定义什么情况需要检查。系统提供证据与提示，获授权人员仍负责实际维修决定。

交付环节	应确认的事情
数据匹配	设备、部件与事件是否正确关联
异常判断	误报和漏报分别造成什么影响
工作安排	提示能否提前进入维护计划
结果回写	处理结果能否回到后续分析

为什么要关注工作安排

即使某种异常能够被识别，组织仍需要人员、备件和时间来处理。试点应检查提示到达后是否发生了正确行动，以及提前量是否足够。单独报告检测准确率，无法说明运营价值。

反过来，某次运营改善也可能同时受到排班、供应和维护政策变化影响。需要保留这些条件，避免把全部变化算给模型或平台。

可复用的 FDE 工作包

准备设备对象字典、事件关联规则、异常样本表和处置记录。以一个范围有限的场景演练从数据到行动再到结果回写的过程。涉及航空安全的系统应接受相关专业审查，本书练习只能使用获授权的非生产数据。

资料没有说明什么

公开材料没有给出所有航空公司的具体实现、人员投入、维护成本和独立因果评估。读者不能据此推定任何相似组织都会获得相同收益。

来源与回读

- [Airbus 发布 Skywise](#)
- [Airbus 早期采用说明](#)
- 回读第 6 章的数据对象与第 3 章的价值衡量。

第 20 章 Tampa General，医院运营协同

医院的床位安排涉及清洁、人员、设备与患者流转。优化一个局部步骤以后，其他条件仍可能限制整条流程。这个案例适合练习怎样界定业务指标。

公开事实与证据

Tampa General Hospital 在 2024 年 6 月的公告中介绍了与 Palantir 扩大合作，以及连通照护协调的计划。公告报告病床分配速度提高 83%、术后恢复区域的停留时间减少 28% 等结果。

证据等级为 A，属于医院发布方报告。公开公告没有提供完整样本、同期对照与各项指标的计算过程。这些数字不应被改写为 AI 单独导致的临床效果。

从局部速度走到完整流程

病床安排更快，不必然意味着患者已经更快进入病房。房间可能等待清洁，人员或设备可能尚未就绪。流程测量需要区分申请、匹配、准备、转运与实际到达等事件。

以下属于本书分析与教学设计，证据等级为 D。类似项目可以先建立状态字典，明确每个时间戳由哪个系统产生。对于缺失或延迟更新的状态，系统应显示不确定性，避免把过期记录当成当前事实。

需要测量的阶段	要分清的情况
提交申请到匹配	是否真正找到符合条件的床位
匹配到准备完成	清洁、设备与人员是否就绪
准备到转运	是否存在其他流程等待
到达后核对	系统记录与实际状态是否一致

让专业人员保留决定权

流程建议可能涉及患者隔离、监护和其他专业要求。系统应将约束作为明确规则，并把无法满足条件的情况交给获授权人员。自动选择一个看起来可用的床位，不代表它满足临床需要。

对状态变化频繁的场景，还要检查并发。两位操作人员同时接受同一资源建议时，最终分配必须由可信系统核对，不能只依赖界面显示。

可复用的 FDE 工作包

制作事件时间轴、状态定义、资源约束和异常接管表。用合成数据重放流程，比较局部用时与端到端用时。项目涉及医疗机构时，需要该机构的临床、信息与隐私团队审核；本书不提供患者处置建议。

资料没有说明什么

公告没有披露完整架构、各环节成本和对照方法。不能由运营指标推导患者层面的医疗结论，也不能把这里的效果阈值用于其他医院验收。

来源与回读

- [Tampa General 的合作公告](#)
- 回读第 2 章的流程观察与第 10 章的责任边界。

第 21 章 Morgan Stanley，把评测放进开发

知识助手与会议纪要看起来都是文字任务，验收重点却不同。前者要准确找到和解释证据，后者要完整记录重要信息与待办，不能擅自增加承诺。

公开事实与证据

OpenAI 与 Morgan Stanley 的案例介绍了内部知识助手和 Debrief 会议工具。团队在部署前使用领域评测，并持续检查结果。Debrief 在取得客户同意后处理会议录音，生成笔记及后续草稿，由顾问复核。发布方报告超过 98% 的顾问团队使用内部助手。

证据等级为 A，来源为联合客户故事。采用比例反映该材料的统计口径，不能直接证明收入提升或每条回答正确。

评测为什么需要分任务

以下是本书的分析与教学设计，证据等级为 D。知识问答应检查资料是否相关、引用是否支持结论，以及用户是否具有访问权。会议工具还要检查参与者、行动负责人、约定日期与待确认事项。

同一句含糊表达，在检索任务里可能需要补问，在会议纪要里则应保留不确定性。把两种应用交给同一个笼统的「回答质量」评分器，会掩盖重要区别。

应用	应优先检查的失败
知识检索	旧政策、错误引用与越权资料
会议笔记	漏掉限制、错认人物和虚构行动项
后续草稿	添加未经同意的承诺
系统写入	重复记录与错误关联客户

把顾问的修正用于改进

用户修改输出可以形成有价值的反馈，但需要分类。修正事实与调整语气的意义不同。将所有编辑都当成模型错误，会使评测目标变得混乱。

记录修改原因后，可以形成新的测试样本。仍需检查是否获得数据使用许可，并去掉不必要的客户信息。测试集中的敏感资料也需要权限与保留规则。

可复用的 FDE 工作包

准备两套分别面向问答与会议的评测表，定义严重错误、人工确认与写入规则。用模拟材料完成「草稿、复核、确认、写入」的演练，检查取消和重复提交两条路径。

资料没有说明什么

客户故事没有提供完整评测集、所有阈值、成本与独立对照。公开方案也不构成对金融机构数据或业务合规的通用承诺。

来源与回读

- [Morgan Stanley 的评测与采用案例](#)
- 回读第 7、9、10 章。

第 22 章 BBVA，从试用走向组织采用

当 AI 使用从小规模试点扩展到多个部门，问题会从单个输出转向身份、数据政策、培训和支持。BBVA 的案例提供了观察组织采用的材料。

公开事实与证据

2026 年 6 月的 OpenAI 客户案例回顾 BBVA 从 2024 年的 3,000 名员工试点扩大使用。页面报告全球约 100,000 名员工使用 ChatGPT Enterprise，月活超过 70%，平均每人每周节省约三小时。材料还介绍了内部冠军用户与高级用户参与培训和推广。

证据等级为 A，属于发布方报告。时间节省的测量方法和岗位差异未完整公开。本章不把平均节时换算为裁员人数或已兑现利润。

使用人数扩大以后要补什么

以下为本书分析与教学设计，证据等级为 D。个人可以自行处理的一些小问题，在组织规模下会成为持续运营工作。谁能共享助手、资料更新后谁负责、部门成员离开后权限怎样处理，都需要明确规则。

培训可以解释基础使用方法，部门支持人员还需要理解实际任务。当用户不知道某类数据能否输入时，应该有清楚的查询与审批路径，而非自己猜测。

扩张环节	对应的运行能力
更多用户	身份管理与支持渠道
更多部门	数据规则与角色差异
更多共享助手	所有者、评测与退役机制
更多业务动作	接口、授权和人工确认

从个人节时转向流程结果

员工使用工具更熟练以后，可以选择稳定任务做流程级试点。先确认原有处理步骤与基线，再决定是否开发共享工具或集成应用。没有必要把每一种个人提示都包装成正式系统。

冠军用户能够收集问题并帮助同事，但不能代替技术支持和风险审批。组织应该给他们清楚的边界，避免热心用户承担自己无权解决的问题。

可复用的 FDE 工作包

制作允许任务清单、共享助手登记表、部门支持流程和采用指标表。共享助手至少记录负责人、数据范围、使用对象、评测记录和停用办法。

资料没有说明什么

页面未提供全部国家与岗位的分布、成本、调查方法及各用例长期结果。高采用可以支持继续研究，但不能单独证明每个流程都值得自动化。

来源与回读

- **BBVA 的联合案例**
- 回读第 3、16、17 章。

第 23 章 TIME，在固定期限内交付

与持续演进的内部系统相比，围绕媒体发布的项目往往有明确日期。上线时间固定时，工程团队需要控制功能范围，并安排每一部分的验收。

公开事实与证据

Scale AI 的 TIME 案例介绍了围绕 2024 年年度人物内容的互动体验，包括文本与语音交互、多语言能力，以及基于 TIME 内容的问答。发布方称项目从提案到生产用时不到两个月，并进行了包含约 7,000 条攻击向量的测试。

证据等级为 A，来自服务商客户故事。测试数量只能说明公开材料报告的工作量，不能证明所有攻击均被阻止，也不能替代质量结果。

多种能力需要分别验收

以下为本书分析与教学设计，证据等级为 D。文字回答正确，不意味着语音转写、翻译与播放都正确。应分别检查内容、语言、音频和界面，再测试用户从提问到获取答案的完整过程。

任务	应独立检查的内容
内容问答	引用是否支持回答、是否越出材料范围
多语言	人名、专名与语义是否保持一致
语音输入	噪声与识别错误怎样处理
语音输出	播放失败时是否仍可读文字
发布页面	流量、延迟与不可用时的提示

固定期限下的取舍

明确必须上线的体验，再设置可以取消的功能。若某种语言来不及完成合格审校，缩小支持范围比在发布时隐藏质量风险更稳妥。

同时准备分层回退。语音不可用时保留文字，互动服务不可用时仍让读者访问原文。这样的设计减少单个依赖故障对内容阅读的影响。

内容授权也要在开发前确认。可以读取公开网页，不代表可以任意训练、复制或商业改编其中内容。项目需要按实际许可确定可用范围。

可复用的 FDE 工作包

准备功能优先级、语言与能力测试表、内容授权记录和回退方案。安排一次上线演练，逐个关闭依赖，观察用户是否仍能完成最低限度的阅读任务。

资料没有说明什么

材料未给出完整用户规模、转化数据、全部测试结果与长期运营成本。不到两个月的交付时间不能直接用作其他项目的工期承诺。

来源与回读

- [Scale AI 与 TIME 的案例](#)
- 回读第 12、13、14 章。

第 24 章 GitLab，区分产品与内部应用

一家公司可以同时把模型接进商业产品，又让自己的员工使用模型。它们可能共享经验，却需要不同的数据规则和验收标准。

公开事实与证据

Anthropic 发布了两份 GitLab 案例。一份讲 Claude 进入 GitLab Duo 及模型评估，另一份讲员工使用 Claude Enterprise 处理写作、研究和其他内部任务。内部采用材料报告的满意度与效率变化，属于内部试点口径，不能当作 Duo 客户的产品效果。

证据等级为 A，来源为供应商客户故事。两条应用路线的对象与测量不同，本章不合并它们的结果。

为什么要分开验收

以下是本书分析与教学设计，证据等级为 D。产品功能面对外部客户，需要考虑租户隔离、版本稳定、服务支持和功能回退。员工应用更关注允许输入的数据、共享范围、输出复核与部门采用。

代码生成、漏洞解释和文档总结也不能共用一个简单成绩。代码可以通过编译与测试检查部分质量，漏洞修复还需安全审查，文档总结则要检查事实与覆盖。

维度	对外产品	内部应用
使用对象	客户与其组织	员工与部门
重点控制	租户、发布、产品质量	保密、共享与复核
价值衡量	客户任务与功能采用	内部任务周期与质量
回退方式	按功能或客户群回退	暂停特定用途或共享助手

共用经验而不混用数据

内部用户发现的术语问题，可以帮助改善说明与评测。但客户代码和商业资料不能因此自动进入内部实验。形成共享经验时，应保留脱敏、授权与使用范围。

模型选择也应按任务验证。增加供应商可能带来质量或可用性收益，同时增加配置、监控和维护工作。只有真实测试支持相应收益时，才值得保留这种复杂性。

可复用的 FDE 工作包

制作两份分开的验收表，再建立任务级模型登记表。记录允许数据、质量要求、回退模型与责任人。选择一个模型变更，演练按功能回退，确认不会影响无关功能。

资料没有说明什么

公开页面未给出全部任务成绩、内部调查样本、成本和长期留存。材料中的主观效率感受不等同于独立测量的工程产能。

来源与回读

- [GitLab 产品集成案例](#)
- [GitLab 内部采用案例](#)
- 回读第 9、14、17 章。

第 25 章 Assembled，客服系统的韧性

客服应用既要处理普通问题，也要在模型或工具故障时继续服务。Assembled 的案例把评测、人机分工与依赖切换联系起来。

公开事实与证据

Anthropic 的案例介绍 Assembled Assist 如何评测回复、利用人工修改改进系统，并在 AI 与人工之间安排任务。材料还报告，一次其他模型供应商故障期间，团队在约二十分钟内将工作流切换到 Claude。

证据等级为 A，属于供应商客户故事。公开说明不能证明切换后的每一种任务质量完全相同，也不能保证其他系统获得相同恢复速度。

人工修改怎样成为证据

以下为本书分析与教学设计，证据等级为 D。客服修改了回答，可能是在纠正事实，也可能只是改变语气。应先给修改分类，再决定是否进入标准样本。人工编辑同样可能出错，因此仍需抽样复核。

路由也需要评测。身份异常、政策例外和无法撤销的操作，应有明确接管条件。系统转交人工时，把已核实的信息与待处理事项一起交过去，减少用户重复解释。

要评测的对象	可观察的结果
回答	事实、政策、语气与完整性
路由	是否在需要时转交正确团队
工具	参数、权限、执行状态
接管	背景是否完整、是否重复询问
最终服务	解决、重开、再次联系与投诉

切换能力需要平时准备

备用模型应通过关键任务与工具测试。故障发生时，可以先进入保守模式，降低自动执行范围，保留人工渠道。恢复服务之后继续观察质量，不能只检查接口是否响应。

自动化比例越高，人工队列的组成也可能改变。剩下的任务更复杂时，不能拿过去平均处理时长直接评价人工团队。运行指标要反映任务难度的变化。

可复用的 FDE 工作包

准备人工修改标签、路由评测集、接管摘要格式和依赖故障演练。对同一批高风险样本比较主模型与备用模型，写下差异以及切换时必须关闭的功能。

资料没有说明什么

公开材料未给出全部评测器误差、客户分布、切换过程中的功能限制和成本。某客户的结果不能直接代表所有部署。

来源与回读

- [Assembled 的公开案例](#)
- 回读第 9、15、16 章。

第 26 章 Klarna，自动化指标的边界

客服自动化最容易被浓缩成几个大数字。Klarna 的案例适合放在后面阅读，因为读者此时已经能够区分工作量、服务质量与财务结果。

公开事实与证据

2024 年的 OpenAI 客户案例报告，Klarna 助手在首月处理约 230 万次对话，约占客服聊天的三分之二；发布方将其工作量描述为相当于 700 名全职客服。页面还报告处理时间与重复咨询的改善。

证据等级为 A，属于联合发布方口径。「相当于 700 人的工作量」不能直接改写为实际裁掉 700 人。预测的财务贡献也不能与后来披露的实际成本节省混为一项数据。

怎样检查自动化是否有效

以下为本书分析与教学设计，证据等级为 D。一次聊天结束，不代表用户问题解决。系统可能把用户引导到别的渠道，用户也可能稍后再次联系。评测需要跨越单次对话，观察重开、重复咨询、投诉与错误操作。

常见指标	必须补问的口径
自动化率	哪类任务、哪个渠道、是否含转人工
处理时长	只看对话还是包含后续处理
解决率	谁确认解决、是否跟踪再次联系
满意度	谁回答调查、未回应者如何处理
成本节省	是否扣除模型、复核与支持成本

保留服务选择与接管

低风险、规则清楚的查询可以先尝试自动处理。涉及身份、争议或特殊政策的情况，需要明确的人工路径。用户不应为了获得人工帮助而反复与系统争辩。

即使低风险任务自动化效果稳定，也要监测流量变化。新的政策、产品或语言都可能改变输入分布。扩大范围之前，用新的样本检查质量，而非直接延用首月结果。

可复用的 FDE 工作包

制作一个分任务客服报告，同时显示自动处理、人工接管、再次联系与投诉。把严重错误单独列出，并为其设置暂停条件。最后把时间节省与实际支出变化分开计算。

资料没有说明什么

早期案例没有披露全部客户分组、长期跟踪与独立对照。它能说明发布方报告的特定阶段结果，无法支持「客服可以全部自动化」或「客服自动化必然失败」这样的结论。

来源与回读

- [Klarna 的早期客服案例](#)
- [Klarna 的后续上市申报材料](#)
- 回读第 3、9、10 章。

第 27 章 Datawhale，从具体业务开始

企业 AI 实践不只发生在大型金融与软件公司。Datawhale FDE100 收录的项目还涉及制造、零售和采购。本章选择两个资料相对完整的案例，观察培训与数据治理怎样进入交付。

公开事实与证据

Datawhale 的制造业培训案例介绍，一家德国零部件企业将经验和文档整理为可检索知识，并接入已有培训平台。发布材料报告带教时间从每周约十小时降至三小时。

另一个工业物料案例介绍，团队先清理 ERP 中重复与不一致的数据，再增加语义检索，帮助用户找到已有物料并减少重复录入。页面没有披露可核对的最终采购节省金额。

证据等级为 C，来自社区审核后脱敏发布的案例自述。页面上的审核标识不等同于独立效果审计。中文实践社区收录的项目也可能发生在海外，不能全部称为中国境内项目。

培训任务怎样使用知识系统

以下为本书分析与教学设计，证据等级为 D。培训问答应区分解释材料与实际操作授权。用户能够答对问题，不一定具备安全操作设备的能力。专业人员仍需按照企业规则进行实际验收。

知识整理时，标准步骤与例外条件应一起保留。经验中的适用范围缺失，可能使新员工把局部方法用于不合适的设备或材料。

培训环节	交付时需要检查
资料整理	版本、适用设备和确认人
问答	证据、拒答与专业人员升级
学习跟踪	完成记录是否真实反映掌握情况

培训环节	交付时需要检查
操作验收	是否仍由获授权人员确认

物料检索为什么先处理数据

同一物料有不同名称与单位时，语义相似度无法独自决定它们能否合并。规格、材料和使用条件可能具有关键差异。数据清理应保留原记录与映射，由业务人员确认重要变更。

检索改善后，价值还需要沿着录入、采购与库存记录继续观察。搜索更容易只是中间结果，实际减少的重复采购才与业务支出相连。没有最终数字时，保留测量办法比补一个看起来合理的收益更有用。

可复用的 FDE 工作包

培训项目可以留下知识版本表、学习任务与实际验收规则。物料项目可以留下字段标准、候选重复清单、确认记录和采购结果跟踪。两者都应嵌入已有工作流程，让维护人能够持续更新。

资料没有说明什么

案例没有披露客户完整身份、全部统计样本、独立审计与长期成本。另一些页面存在摘要与正文不一致的地方，因此本书没有照单收录所有案例或页面指标。

用案例检验自己的方案

选一个自己能合法接触的任务，先留下当前流程和样本，定义允许的数据与动作，再做一个可以测试的完整小应用。请真实使用者判断结果，记录失败，完成交接。前三篇介绍的方法，最终都需要在这样的工作中接受检验。

来源与回读

- [Datawhale 制造业培训案例](#)
- [Datawhale 工业物料案例](#)
- [Datawhale 案例目录](#)
- 回读第 6、7、16 章。